第8轮 / 第1步：耗时模型核对（2026-10-16）

状态：第1步诊断完成；用户已确认第2、3步采用ceil主模型、原OS敏感性，均检查PN≤256/512。时间均为μs（1周期=0.001μs），overhead=0。

三套都是分析模型，均非RTL校准测量。“已有OS”仅表示复用研究函数，不能视为原生PLENA时序。

1.2(a,b) 来源与任务口径；单核串行，无PN搜索；同一135窗

模型	函数与首次可追溯阶段	G / Shared / Gate-Up口径
旧表	shared/timing.phase → dedicated/model.job_cycles → scaling_g64/runtime.schedule	G=MLEN/BLEN；1×F2816；Gate/Up合并phase
第7轮OS	round7/model.gemm → round5/model.projection；同递推见第2/4轮	G=PK；2×F1408；Gate/Up各自排空
ceil	round7/model.gemm(issue_formula)；本实现第7轮	G=PK；2×F1408；三GEMM分别计数

路径前缀均为research/moe_dispatch/；上表缩写shared=plena65536_shared、dedicated=plena65536_dedicated、round7=round7_64k_dualcore_dse、round5=round5_largebatch_compute。旧phase最早可见于未编号Shared-only实验；文件未提交，无法证实轮次/创建时间。R5函数首次提交b095a7de；8记录/归约延迟假设前身见geometry3d(1fcc764a)、R2(2a68dfdb)。全部路径/行号/哈希见model_sources.json。135窗逐专家核对：Routed集合完全相同，只有Shared任务计数改变。

1.2(c) 单GEMM拆解：三表均为点测，无调度/窗口；PN最大512（含主cap256外参照）。每格=C/R/A/O→合计，分别为纯ceil乘加 / 归约排空 / 累加依赖 / 其他；属于公式记账，不是实测停顿。G1=(M,K,N)=(1,2048,1408)，G2=(4,2048,1408)，G3=(1,1408,2048)。

旧phase；单位μs

PM×PN×G	G1：C/R/A/O→合计	G2：C/R/A/O→合计	G3：C/R/A/O→合计
1x512x64	0.096/0.006/0.000/0.012 → 0.114	0.384/0.006/0.000/0.012 → 0.402	0.088/0.006/0.000/0.012 → 0.106
1x256x64	0.192/0.006/0.000/0.012 → 0.210	0.768/0.006/0.000/0.012 → 0.786	0.176/0.006/0.000/0.012 → 0.194
4x256x64	0.192/0.006/0.000/0.015 → 0.213	0.192/0.006/0.000/0.015 → 0.213	0.176/0.006/0.000/0.031 → 0.213
2x256x64	0.192/0.006/0.000/0.013 → 0.211	0.384/0.006/0.000/0.013 → 0.403	0.176/0.006/0.000/0.013 → 0.195
32x32x64	1.408/0.006/0.000/0.043 → 1.457	1.408/0.006/0.000/0.043 → 1.457	1.408/0.006/0.000/0.683 → 2.097

第7轮OS；单位μs

PM×PN×G	G1：C/R/A/O→合计	G2：C/R/A/O→合计	G3：C/R/A/O→合计
1x512x64	0.096/0.012/0.372/0.002 → 0.482	0.384/0.048/1.488/0.008 → 1.928	0.088/0.012/0.231/0.002 → 0.333
1x256x64	0.192/0.012/0.279/0.002 → 0.485	0.768/0.048/1.116/0.008 → 1.940	0.176/0.012/0.147/0.002 → 0.337
4x256x64	0.192/0.012/0.279/0.002 → 0.485	0.192/0.012/0.279/0.002 → 0.485	0.176/0.012/0.147/0.002 → 0.337
2x256x64	0.192/0.012/0.279/0.002 → 0.485	0.384/0.024/0.558/0.004 → 0.970	0.176/0.012/0.147/0.002 → 0.337
32x32x64	1.408/0.072/1.426/0.012 → 2.918	1.408/0.072/1.426/0.012 → 2.918	1.408/0.096/1.176/0.016 → 2.696

ceil；单位μs

PM×PN×G	G1：C/R/A/O→合计	G2：C/R/A/O→合计	G3：C/R/A/O→合计
1x512x64	0.096/0.000/0.000/0.000 → 0.096	0.384/0.000/0.000/0.000 → 0.384	0.088/0.000/0.000/0.000 → 0.088
1x256x64	0.192/0.000/0.000/0.000 → 0.192	0.768/0.000/0.000/0.000 → 0.768	0.176/0.000/0.000/0.000 → 0.176
4x256x64	0.192/0.000/0.000/0.000 → 0.192	0.192/0.000/0.000/0.000 → 0.192	0.176/0.000/0.000/0.000 → 0.176
2x256x64	0.192/0.000/0.000/0.000 → 0.192	0.384/0.000/0.000/0.000 → 0.384	0.176/0.000/0.000/0.000 → 0.176
32x32x64	1.408/0.000/0.000/0.000 → 1.408	1.408/0.000/0.000/0.000 → 1.408	1.408/0.000/0.000/0.000 → 1.408

1.2(d) 公式：令 a=⌈M/PM⌉，b=⌈N/PN⌉，k=⌈K/G⌉，C=abk。以下公式单位为周期。

旧phase：BLEN=PM，MLEN=PM·G；T=ab·PM·⌈K/(PM·G)⌉ + PM+11+$\log_2$G。R=$\log_2$G，A=0，O=ab[PM⌈K/(PM·G)⌉−k]+PM+11。Gate/Up合并时records翻倍但只收一次排空，所以整专家不能简单加三个独立phase。

第7轮OS：L=3+2$\log_2$G=15，按N分组q=min(8,剩余列tile)。T=aΣq{qk+(k−1)max(0,L−q)+(L−1)}；A=aΣq(k−1)max(0,L−q)，R=2$\log_2$G·a·组数，O=2a·组数。R/O只是L−1的代数拆分；源函数没有独立归约/累加计数器。ceil：T=C，R=A=O=0。

第8轮 / 第1步：证据、逐任务对账与主模型建议

1.2(d) 硬件依据核验；静态源码审查，无额外硬件实验

依据	能支持什么	不能支持什么
PLENA §III-B / 图5、6	OS部分和驻PE；子阵列间M_SUM；连续tile流水化	没有8上下文、每K段15周期依赖的依据
customISA_lib.json:2–5	M_MM独立2·BLEN+9，流水间隔BLEN	没有旧模型完整M_SUM/shadow-bank重叠依据
fp_sum_across_sa / fp_default_pe RTL	跨阵列加法树及PE局部累加存在	没有本实验8记录、2log₂G+3的校准依据
Rust matrix_machine.rs:143/512；matrix_service.rs:1/120	原路径另收overhead+MLEN；候选service可配MAC/tree延迟	均非R7函数；候选service自身声明未综合

为什么宽核变慢：N=1408时，PN256有6个独立输出tile，PN512只有3个。R7模型强制回访同一输出间隔≥15周期；因此G1的纯乘加从0.192降为0.096μs，依赖等待却从0.279增为0.372μs，合计只从0.485降到0.482μs。这是有限上下文和发射顺序假设的后果，不是单行核必然物理缓慢；8记录本身也不等于必须按小组排空。

1.2(e) 窗口 heldout_bfcl_b2_l2_s3：4×256×64（PN≤256），单核顺序执行；2请求同一decode步3、层2。12个Routed均Me=1、Shared Me=2；路由总数12=6B。

逐任务时长（μs）；旧Shared为一个F2816任务，不虚构拆分归属

任务	Me	旧表模型	第7轮OS	ceil
Shared A，F1408	2	合并共1.098	1.307	0.560
Shared B，F1408	2	已含上格	1.307	0.560
R10	1	0.618	1.307	0.560
R14	1	0.618	1.307	0.560
R17	1	0.618	1.307	0.560
R18	1	0.618	1.307	0.560
R20	1	0.618	1.307	0.560
R24	1	0.618	1.307	0.560
R33	1	0.618	1.307	0.560
R36	1	0.618	1.307	0.560
R43	1	0.618	1.307	0.560
R51	1	0.618	1.307	0.560
R54	1	0.618	1.307	0.560
R55	1	0.618	1.307	0.560
专家合计	—	8.514	18.298	7.840
控制开销 / 窗口总计	—	0.005 / 8.519	0 / 18.298	0 / 7.840

任务核对：普通专家旧模型=0.405(Gate+Up)+0.213(Down)=0.618；R7 OS=0.485+0.485+0.337=1.307；ceil=0.192+0.192+0.176=0.560μs。旧合并Shared=0.725+0.373=1.098μs；新增控制只在旧重放收0.005μs。

27个B2窗口；形状4×256×64 / PN≤256 / 单核；统一算术平均与原表对照

模型	原表采用统计	纯乘加	依赖等待	其余算术/控制	总计（AM）
旧表	GM=7.605794	—	单独收费0	全部服务+控制	7.672111
第7轮OS	AM=16.506926	7.072593	8.903889	0.530444	16.506926
ceil	AM=7.072593	7.072593	0	0	7.072593

B2活跃数直方图 A:n={7:2,8:2,9:1,10:4,11:8,12:10}，E[A]=10.629630。旧每窗总计=(618A+1098+5)/1000；ceil=(560A+1120)/1000；R7 OS=(1307A+2614)/1000。换成合并Shared，R7 OS的AM仅降0.009μs、ceil降0.064μs；Shared拆分不是2倍差距主因。

第4项只读检查：纯decode trace存在：final_artifacts/moe_regime_20261005_v1/payload/inputs/heldout.json，108窗，B2/4/8/16各27，层2/13/26、步3/7/11，BFCL/GPQA/SWE，每窗来自B个不同请求。另27窗在mixed_heldout.json：B64/96/128各9，层相同、decode步7，16个decode token + 同一请求连续prefill前缀48/80/112。后者必须标注decode+prefill混合窗口；18窗还带capture_prefix_smoke=true。逐窗来源保留原始数据，不重采样。

建议：纯计算几何研究暂以ceil为主模型（理想发射下界，非真实PLENA延迟）；原8记录/15周期模型只保留敏感性。旧模型虽更接近论文拓扑，G语义、合法形状、融合及排空假设不同，也未完成BF16校准，不能直接替代。若要求真实硬件结论，需要先确定并校准BF16数据通路、累加反馈和上下文资源。用户已确认ceil主模型、原OS敏感性及PN≤256/512；完整后续结果见results.md。