



MoE固定形状对照：计算收益能否转化为总延迟收益？
BF16 | a=6×4×512；b=3×4×512两核；c=4×4×512+2×4×512

① 原配置总延迟：单核更快



② 理想供数计算对照：双核计算更快



③ 输入与共同取数下限（每Batch 27窗口）

Batch	热专家 Me>2	冷专家 Me=1或2	Shared	权重 MB	取数下限 ms
B2	0.00	10.63	1	218.5	1.7338
B4	0.70	18.56	1	367.8	2.9185
B8	6.56	18.59	1	469.7	3.7269
B16	12.74	22.04	1	636.3	5.0489

专家数是窗口平均值；冷专家仍然活跃。
两核共用HBM；分核不减少这些权重字节。

④ B8吞吐：必须区分两种时间分母

组织	取数等效 GB/s（总延迟）	计算对照 GFLOP/s	端到端 GFLOP/s
单核 6	125.87	1691	296.73
同构 3+3	120.17	3110	283.28
异构 4+2	119.88	3245	282.61

同字节和有效MAC时，两个总延迟口径的
吞吐排序都由总延迟的倒数决定。


MoE固定形状BF16：将预期排序改为实际模型结果
a 单核6×4×512 | b 同构3×4×512两核 | c 异构4×4×512+2×4×512

Batch	组织	原配置 总延迟 ms	HBM取数 下限 ms	计算对照 时间 ms	取数等效 GB/s	总延迟口径 GFLOP/s	计算对照口径 GFLOP/s	发射空间 利用率 %
B2	单核 6	1.7359	1.7338	0.3016	125.88	159.47	917.7	20.5
B2	同构 3+3	1.8451	1.7338	0.1557	118.43	150.03	1777.8	41.0
B2	异构 4+2	1.8451	1.7338	0.1557	118.43	150.03	1777.8	41.4
B4	单核 6	2.9221	2.9185	0.5086	125.88	189.47	1088.5	24.3
B4	同构 3+3	3.0822	2.9185	0.2626	119.34	179.63	2108.6	44.3
B4	异构 4+2	3.0822	2.9185	0.2628	119.34	179.63	2106.4	45.8
B8	单核 6	3.7316	3.7269	0.6547	125.87	296.73	1691.3	35.2
B8	同构 3+3	3.9088	3.7269	0.3560	120.17	283.28	3110.4	59.2
B8	异构 4+2	3.9181	3.7269	0.3413	119.88	282.61	3244.8	62.4
B16	单核 6	5.2779	5.0489	0.9134	120.56	419.59	2424.5	46.8
B16	同构 3+3	5.5954	5.0489	0.5222	113.72	395.79	4241.2	70.2
B16	异构 4+2	5.3931	5.0489	0.4969	117.99	410.64	4457.2	70.9


108个捕获路由窗口；每个Batch 27个，时间列为窗口均值。精度仅BF16输入/权重、FP32累加。
取数下限、计算对照不是总延迟的两个可加分项；实际native取数跨度与HBM忙碌时间尚未测量。
发射空间利用率只统计已发射的MAC槽，不包含阵列空等周期；计算对照并非实际运行中的计算占比。

瓶颈诊断与驻留组对照：硬件、精度、带宽预算不变

B8单项计时神谕（固定原归属）



共同编译器规则：预留足够权重前瞻空间



左：非物理计时神谕，节省不可相加。右：映射改变，X复用/计算反馈可能改变；不是异构专属优化。